

중고차 가격 예측 모델 개발

종합 실습 보고서

29기 B1

김민규 김예슬 양현준 오수빈 조한흠 천정화



목차

CONTENTS

01

과제 정의

02

데이터 현황

03

탐색적 분석 및 데이터 전처리

04

모델 정의 및 설명

05

모델 학습 및 결과

06

결론 및 대안제시

07

참고문헌 및 소감

01 과제 정의

인도 중고차 시장




지속적인 성장세

2023년 기준 561억 달러 규모
연평균 성장률은 약 3.1%
꾸준한 성장세



수입 자동차에 대한 높은 세율

수입 자동차 최대 100% 관세
수입 자동차의 초기 구매 비용 증가



중고차 시장 시스템 미정립

독립 딜러 48%
개인간 직거래 29%
가맹점 인증 중고차 23%

중고차 시장에 뛰어든 최적의 타이밍

- 급성장하는 인동차 시장에서 선점효과를 통해 초기 시장 점유율을 확보
→ 경쟁 우위를 강화
- 투명한 가격 책정과 데이터 기반 서비스 제공으로 소비자의 신뢰를 구축
- 가격예측모델을 통해 중고차 평가 시간을 단축하고 거래 프로세스 간소화


01 과제 정의

인도 중고차 시장에서의 핵심 영향 인자 도출 및 가격 예측 모델을 통한 성공적인 스타트업 출범

- 학습 전 모델 알고리즘을 통해 확인하고자 하는 요소
 - 어느 지역에서 사업을 시작해야 안정적인 수익을 보장하면서 버틸 수 있는가?
 - 팔기 위한 중고차를 매입할 때 어떤 변수를 중심으로 매입 기준을 세워야 하는가?
 - 어느 브랜드가 가장 잘 팔리는가?

02 데이터 현황 - 변수 설명

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	Name	5952 non-null	object
1	Location	5952 non-null	object
2	Price	5095 non-null	float64
3	Year	5952 non-null	int64
4	Kilometers_Driven	5952 non-null	int64
5	Fuel_Type	5952 non-null	object
6	Transmission	5952 non-null	object
7	Owner_Type	5952 non-null	object
8	Mileage	5950 non-null	object
9	Engine	5926 non-null	object
10	Power	5926 non-null	object
11	Seats	5923 non-null	float64
12	New_Price	933 non-null	object




데이터 설명

- 브랜드& 모델 이름 - 범주형
- 팔거나 구매할 수 있는 위치 - 범주형
- **가격(단위 : 1,000원) - 연속형**
- 모델의 년도 / 버전 - 연속형
- 이전 소유주의 차량 주행거리(km) - 연속형
- 연료의 종류 - 범주형
- 변속기 종류 - 범주형
- 직접 소유, 중고소유 여부 - 범주형
- 회사가 제공하는 표준주행거리(kmpl)
- 엔진의 배기량 (cc) - 연속형
- 엔진의 최대 출력(bhp) - 연속형
- 차의 좌석 수 - 연속형
- 뉴 모델의 가격 - 연속형


02 데이터 현황 - 데이터 분포 확인

● 전체 데이터 분포 특성 및 변수 간 관련성 확인

01. Heat map



02. Scatter Matrix



02 데이터 현황 - 데이터 분포 확인

1. Numeric 변수 - 특수값 및 이상치 발견

	Price	Year	Kilometers_Driven	Mileage	Engine	Power	Seats
count	6200.000000	7253.000000	7.253000e+03	7251.000000	7207.000000	7078.000000	7200.000000
mean	14912.514750	2013.365366	5.869906e+04	18.141580	1616.573470	112.765214	5.279722
std	17674.318464	3.254421	8.442772e+04	4.562197	595.285137	53.493553	0.811660
min	7.080000	1996.000000	1.710000e+02	0.000000	72.000000	34.200000	0.000000
25%	5365.360000	2011.000000	3.400000e+04	15.170000	1198.000000	75.000000	5.000000
50%	8814.520000	2014.000000	5.341600e+04	18.160000	1493.000000	94.000000	5.000000
75%	15869.972500	2016.000000	7.300000e+04	21.100000	1968.000000	138.100000	5.000000
max	245273.600000	2019.000000	6.500000e+06	33.540000	5998.000000	616.000000	10.000000

2. Object 변수 - 다수의 결측치 및 너무 많은 범주형 특이값 발견

	Name	Location	Fuel_Type	Transmission	Owner_Type	New_Price
count	7253	7253	7253	7253	7253	1006
unique	2041	11	5	2	4	625
top	Mahindra XUV500 W8 2WD	Mumbai	Diesel	Manual	First	63.71 Lakh
freq	55	949	3852	5204	5952	6

03 탐색적 분석

● 탐색적 분석 및 전처리 계획

결측치 및 이상치	파생변수	공선성/데이터 변환	의미 없는 데이터 제거
- 결측치 - 결측치 확인 및 원인 분석 - 결측치의 제거, 보간 여부 결정 - 이상치 - 연속형 변수의 경우 이상치 범위 결정 및 처리 - 범주형 변수의 경우 정상 값 기준 결정 및 처리	- 변수 설명력을 높이기 위한 파생변수 생성 - 직관적 해석력 증가 - 값에 따른 가중치 감소 (연도의 경우)	- 설명변수 간의 상관관계 분석 - 다중공선성 문제 확인 - pairplot을 통한 변수간 선형성 파악 - 상관계수를 사용한 변수간 관계성 파악 - 범주형 자료의 더미변수화 - 값에 따른 가중치가 있는 변수의 경우, 라벨링 적용	- 확인된 다중공선성 문제 해결 - 선형 관계를 가진 변수를 파악 - 파생변수를 생성한 기존 변수 제거 - 기존의 변수로부터 정보를 얻고 난 뒤의 기존 변수 제거




핵심 영향인자 도출

03 탐색적 분석 - 결측치 처리

```
print(df.shape)
```

```
(7253, 13)
Location      0
Price        1053
Year          0
Kilometers_Driven  0
Fuel_Type     0
Transmission  0
Owner_Type    0
Mileage        2
Engine        46
Power         46
Seats         53
New_Price     6247
dtype: int64
```



New_Price


: 전체 7253 데이터 중 86%이상 결측치
→ 컬럼삭제

이 외 결측치



'Price' → 목표변수이므로 처리 불가, 제거
'Mileage', 'Engine', 'Power', 'Seats'
→ 함께 결측치이거나, 갯수가 적으므로 제거

03 탐색적 분석 - Year

- 범위탐색 및 파생변수 생성




'Year' 데이터는 연도로 되어있어 연산이 어려움





가장 최근 데이터인 2020를 기준으로 연식을 뺀
'차량 나이(Car_age)' 파생변수 생성

03 탐색적 분석 - Seats

- 범위 탐색 및 파생변수 생성




좌석수 data의 분포가 균일하지 않아 범주화하기로 함



2~4 small / 5 medium / 6~7 large / 8이상 x_large

03 탐색적 분석 - Transmission Types


- 범위 탐색 및 갯수확인



" 원핫인코딩을 통해 수치형으로 변환 "

03 탐색적 분석 - Kilometer Driven

- 이상치 탐색 및 제거



20만 마일 이상 이상치 처리

이상치 처리 이유

- 차량의 상태와 상관없이 파손의 위험성 증가
- 소비자의 유지보수 부담
- 변속기 교체필수

탐색적 분석 - 이상치 처리

03 탐색적 분석 - Price

- 이상치 탐색 및 제거

● `df_raw.describe()`

✓ 0.0s

	Price	Year	Kilometers_Driven	Seats
count	6200.000000	7253.000000	7.253000e+03	7200.000000
mean	14912.514750	2013.365366	5.869906e+04	5.279722
std	17674.318464	3.254421	8.442772e+04	0.811660
min	7.080000	1996.000000	1.710000e+02	0.000000


Name	Location	Price	New_Price
Hyundai Elite i20 Magna Plus	Kochi	7.08	7.08 Lakh

- Min 값 이상치 처리

신차값과 중고차 값이 같아
이상치로 간주하여 제거

03 탐색적 분석 - Fuel_Type

- 범위 탐색, 조건 확립





CNG, LPG, Electric 컬럼 삭제

- 디젤 휘발유 제외 비율은 1.05%
→ 모델 학습 시 **과적합/ 왜곡결과** 유발
- 시장대표성 확보** 측면
→ 실제 시장에서 구매자 대부분이 Diesel, Petrol 요구
→ 현재 시장흐름을 대표하는 데이터를 분석이 타당
- CNG/LPG/전기차는 **특수목적/조건**의 차량 가능성
→ 가격책정, 유지비 산정 방식이 일반 승용차와 **다름**

03 탐색적 분석 - Location



● 범위 탐색



- 지도에서의 Location의 값의 실제 분포
- 도시별 평균 가격은 위 그래프와 같음
 - 대체적으로 골고루 분포하는 경향이 있으나
 - 몇몇 도시의 경우 높은 가격, 다수의 거래가 포착됨

03 탐색적 분석 - Location

도시별 가격 분포



가설 검정

귀무가설 : 판매 위치와 가격 평균에 차이가 없다.

F-Statistic: 40.059, p-value: 0.00000

ANOVA를 사용하여 p-value확인 시 0.05 이하
→ 지역에 따라 가격이 유의미하여 컬럼 유지

“귀무가설 기각”

03 탐색적 분석 - Owner Type

- 범위 탐색 및 조건 확립

	Feature	Importance
3	Transmission	0.340235
6	Engine	0.195186
7	Power	0.178830
0	Year	0.141154
1	Kilometers_Driven	0.060086
5	Mileage	0.037042
9	Brand	0.020691
8	Seats	0.017451
2	Fuel_Type	0.006678
4	Owner Type	0.002648


Owner type과 Price의 관계를 고려

- Price에 대한 중요도 측면
: Owner type 의 경우 0.26 % 굉장히 낮음
- 차량 소유자 수가 증가 시 가격 하락률이 가속화
: 4번째 주인부터 시장 내 재판매율이 30% 이상 감소
평균 판매기간도 약 2배 증가.

⇒ 현 중고차기업을 벤치마킹하여
차량의 재고율과 그에 따른 재고유지비 절감측면에서
4번 이상 데이터 제거

03 탐색적 분석 - Engine & Power

- 이상치 확인 및 결정




- 상위 구간에서 극단적인 값
→ 배기량과 마력은 차량 고유의 값
→ 이상치로 간주하지 않기로 결정

03 탐색적 분석 - Engine & Power

- heatmap 확인

```
sns.heatmap(df_drop.corr(), annot=True, cmap='coolwarm')
```





데이터 연관성

Engine과 Power는
0.87의 높은 상관계수를 가짐

Parameter		r
Price	Engine	0.64
Price	Power	0.75
Engine	Power	0.87

03 탐색적 분석 - Engine & Power

- pairplot 확인



Power와 Engine은 선형관계

03 탐색적 분석 - Engine & Power

• 다중공선성 점검

	coef	std err	t	P> t
Intercept	-1.194e+04	426.945	-27.958	0.000
Engine	-1.6407	0.485	-3.382	0.001
Power	261.8502	5.389	48.586	0.000

- Pairplot으로 세 변수 간 양의 상관관계 확인
- Engine은 Price에 대해 음의 회귀 계수를 보임
→ Power와 Engine의 다중공선성을 점검하기로 결정

최소제곱법

Engine과 Power는 Price 변동의
0.579의 설명력

Power는 강한 양의 회귀 계수
Engine은 음의 회귀 계수

ols	Engine	Power
t-value	-3.382	48.586
coef	-1.6407	261.85
R ²	0.579	

03 탐색적 분석 - Engine & Power

- 다중공선성 해결

	variable	VIF
20	Owner_Type_Fourth & Above	1.01
22	Owner_Type_Third	1.05
1	Kilometers_Driven	1.05
21	Owner_Type_Second	1.08
17	Fuel_Type_LPG	1.19
5	Seats	1.81
19	Transmission_Manual	1.81
6	Location_Bangalore	2.43
11	Location_Jaipur	2.63
2	Mileage	2.73
7	Location_Chennai	2.92
13	Location_Kolkata	3.08
9	Location_Delhi	3.15
15	Location_Pune	3.31
8	Location_Coimbatore	3.47
12	Location_Kochi	3.51
10	Location_Hyderabad	3.71
14	Location_Mumbai	3.95
4	Power	6.78
3	Engine	9.06

Power의 VIF = 6.78

	variable	VIF
19	Owner_Type_Fourth & Above	1.01
21	Owner_Type_Third	1.05
1	Kilometers_Driven	1.05
20	Owner_Type_Second	1.08
16	Fuel_Type_LPG	1.19
4	Seats	1.50
18	Transmission_Manual	1.80
2	Mileage	2.18
5	Location_Bangalore	2.43
3	Power	2.50
10	Location_Jaipur	2.63
6	Location_Chennai	2.92
12	Location_Kolkata	3.07
8	Location_Delhi	3.15
14	Location_Pune	3.31
7	Location_Coimbatore	3.47
11	Location_Kochi	3.51
9	Location_Hyderabad	3.71
13	Location_Mumbai	3.95

Engine의 VIF = 9.06



VIF 변화

Engine 컬럼을 제거 후
Power의 다중공선성이 크게 떨어짐

“Engine 컬럼 제거”

03 탐색적 분석 - Name

- 이상치 판단 및 제거




가격에 대한 정보가 없거나 표본이 적은 경우 (30미만)

: 전체 가격 예측에 **노이즈**로 작용할 것으로 판단하여 **데이터 제외**

03 탐색적 분석 - Name

- 이상치값 제거 예외

Jeep



	Name	Location	Price	Year
568	Jeep Compass 2.0 Limited	Jaipur	29126.24	2018
940	Jeep Compass 2.0 Limited 4X4	Mumbai	30659.20	2017
1039	Jeep Compass 1.4 Limited Option	Mumbai	27210.04	2017
1824	Jeep Compass 2.0 Limited Option Black	Mumbai	26750.15	2017
1991	Jeep Compass 2.0 Longitude	Kochi	26090.98	2018
2061	Jeep Compass 2.0 Longitude	Coimbatore	29202.89	2018
2563	Jeep Compass 2.0 Limited 4X4	Coimbatore	33249.90	2018
2916	Jeep Compass 2.0 Limited 4X4	Coimbatore	36653.07	2019
2959	Jeep Compass 2.0 Sport	Hyderabad	25907.02	2017
3006	Jeep Compass 2.0 Limited	Pune	28359.76	2018
3244	Jeep Compass 2.0 Limited Option 4X4	Kolkata	26826.80	2017
3544	Jeep Compass 2.0 Limited Option 4X4	Jaipur	30659.20	2017
3584	Jeep Compass 2.0 Longitude	Kochi	29831.40	2018
3943	Jeep Compass 2.0 Longitude	Kochi	26903.45	2018
5049	Jeep Compass 2.0 Sport	Kolkata	22994.40	2017
6586	Jeep Compass 2.0 Limited Option 4X4	Coimbatore	42248.38	2019
7126	Jeep Compass 2.0 Longitude	Kolkata	30674.53	2017
7190	Jeep Compass 2.0 Sport	Delhi	30229.97	2017
7232	Jeep Compass 1.4 Sport	Mumbai	27838.55	2018


표본의 수가 30개 이하지만, 계측된 데이터의 경우 모두 동일 모델을 제공

⇒ Compass모델에 대한 다양한 옵션이 존재해 예측에 수월할 것으로 판단하여 데이터 유지


03 탐색적 분석 - Name

● 이상치값 제거 예외

Porsche




Mini



표본의 수가 30개 이하, 계측 된 데이터의 경우 비슷한 모델을 제공하고, 연식의 차이가 존재
⇒ 동일한 모델명이라도 연식의 차이로 각 데이터의 특성을 반영할 것이라 판단

04 모델 정의 및 설명

- 모델 학습 계획 정의 : 파이프라인




- 전처리 된 데이터는 학습데이터 80%: 검증데이터 20%로 분리하여 각각 학습과 검증에 사용함
- Linear Regression 모델의 경우, Data scaling을 위해 MinMax, Standard, Log Scaling을 사용함
- 모델 검증을 위한 Metric으로는 MSE, MAE, RMSE, MAPE, R2를 사용함

04 모델 정의 및 설명

● 모델 학습 계획 정의 : 모델 설명


의사결정트리

- 트리구조 기반의 알고리즘 모델
- 데이터를 기준에 따라 분기하며 예측 수행
- 직관적, 쉬운 해석모델, 스케일링 불필요




랜덤 포레스트

- 여러개의 decision tree를 결합한 앙상블(bagging) 모델
- 과대적합 방지 가능
- 높은 정확도와 안정성을 제공



04 모델 정의 및 설명

• 모델 학습 계획 정의 : 모델 설명



Gradient Boosting

- 여러개의 decision tree를 순차적으로 결합한 모델
- 이전 모델의 오차를 개선하며 점진적으로 성능 향상
- 예측 성능이 매우 우수함

다중 선형 회귀 모델

- 목표변수와 설명변수의 선형관계를 기반으로 예측하는 모델
- 계산이 간단하며, 예측 결과 해석이 용이함
- 학습 전 데이터 스케일링 필요
- 사용할 Scaling 기법

- MinMaxScaling

$$x_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

- StandardScaling

$$x'_i = \frac{x_i - \mu}{\sigma}$$

- Log Scaling

$$x_i = \log(x_i)$$

04 모델 정의 및 설명

● 모델 학습 계획 정의 : 성능지표

회귀분석 성능지표

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- MSE
 - 회귀모델의 대표적인 성능지표
 - 직관적이며 해석하기 쉬움

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{n}}$$

- RMSE
 - MSE 성능지표에 루트를 씌운 성능지표
 - 이상치에 강하고, 오차를 실제값과 유사한 단위로 변환함

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- MAPE
 - MAE를 퍼센트로 나타낸 성능지표
 - 허용 범위가 존재하기 때문에 비교분석이 쉬움

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

- MAE
 - 단순한 계산으로 모델의 오류를 직관적으로 나타내는 성능지표
 - 모델 결과 해석이 간단하고 직관적임

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- R2
 - 데이터에 대한 모델의 설명력을 보여주는 성능지표
 - 모델의 설명력을 직관적으로 파악할 수 있음

05 모델 학습 및 결과

• 모델 학습 결과 - 성능지표

Train 데이터셋에 대한 성능지표

	MSE	RMSE	MAE	MAPE	R2
Decision Tree	4.324971e+07	6576.451495	3270.327170	0.248279	0.864865
Random Forest	1.989551e+07	4460.438497	1955.465949	0.133397	0.937836
Gradient Boosting	4.499177e+06	2121.126355	1159.316148	0.100358	0.985942
MinMax-LinReg	7.253746e+07	8516.892527	4731.969903	0.554059	0.773355
STD-LinReg	7.253739e+07	8516.888675	4731.849395	0.554029	0.773355
Log-LinReg	3.620705e+07	6017.229791	2673.944265	0.173461	0.929753

Test 데이터셋에 대한 성능지표


	MSE	RMSE	MAE	MAPE	R2
Decision Tree	6.392261e+07	7995.161384	3757.947204	0.333741	0.758658
Random Forest	4.644865e+07	6815.324720	2852.341388	0.264542	0.824632
Gradient Boosting	3.894723e+07	6240.771310	2466.482400	0.239358	0.852953
MinMax-LinReg	6.843481e+07	8272.533318	4771.001130	0.620768	0.741622
STD-LinReg	6.843261e+07	8272.400569	4770.834744	0.620728	0.741630
Log-LinReg	5.273780e+07	7262.079436	2865.926091	0.255707	0.892790

모델 학습 결과 분석


- 성능지표를 분석하였을 때
R-squared 기준 다중선형회귀모델
나머지 다른 성능지표 기준, Gradient Boosting 모델의 성능이 좋게 나옴
- 각 지표에 Standard Scaler를 적용한
그래프를 보았을 때도 다중선형회귀모델과
Gradient Boosting 모델의 성능이 좋은것
을 확인 할 수 있음

05 모델 학습 및 결과


● 모델 학습 결과 - 성능지표




Train 데이터셋



Train 데이터셋



Test 데이터셋









Test 데이터셋

05 모델 학습 및 결과

● 모델 학습 결과- 회귀 그래프(Train 데이터셋 기준)







- 의사결정트리를 제외한 다른 회귀모델들이 회귀선을 따라 잘 분포되어있음
- 특히 그중에서도, Gradient Boosting, Log-다중선형회귀모델의 결과가 회귀선을 따라 잘 분포되어있음




05 모델 학습 및 결과

● 모델 학습 결과- 회귀 그래프(Test 데이터셋 기준)

- 의사결정트리를 제외한 다른 회귀모델들이 회귀선을 따라 잘 분포되어있음
- 특히 그중에서도, Gradient Boosting, Log-다중선형회귀모델의 결과가 회귀선을 따라 잘 분포되어있음



06 결론 및 대안제시 - 변수 중요도를 중심으로





Feature	Importance
Power	0.686018
Car_Age	0.182513
Brand	0.040966
Mileage	0.039440
Kilometers_Driven	0.027468
Location	0.009924
Transmission	0.005458
Fuel_Type	0.003591
Seats_cat	0.003150
Owner_Type	0.001471

- 가장 성능이 좋았던 트리 기반 모델중 하나인 Gradient Boosting의 최고 성능 모델을 통해 변수 중요도를 측정
- one-hot encoding을 통해 분리된 변수들의 중요도는 하나로 합하여 계산함
- Power(출력, 마력)이 68.6 %로 가장 높았으며, 그 뒤를 Car_Age(연식), Brand(차량 브랜드), Mileage(연비) 가 순서대로 높은 중요도를 가짐
- 이는 중고차의 가격을 결정할 때, 차량의 컨디션 및 여러 특징이 영향을 미치는 것을 나타냄
 - (주) Pos-Car 에서 중고차를 매입할 때, 관련 기준을 정하고 주요하게 보아야 하는 변수들이라고 판단됨

06 결론 및 대안제시 - 변수 중요도를 중심으로



● Location 측면



- Location 변수만 사용하여 모델 학습을 시켰을 때, 특정 지역의 영향도가 높은 것을 확인
- 실제 예측 모델에서는 총 변수의 중요도 합이 0.009이므로, 중고차 가격을 예측하는데에 큰 영향이 없다고 판단됨
- 그러나 스타트업의 특성상, 안정적인 수입을 얻을 수 있는 곳을 선호한다고 생각하여 사업의 시작 도시를 Coimbatore를 추천함

06 결론 및 대안제시 - 변수 중요도를 중심으로

● Brand 측면



- Brand 변수만 사용하여 모델학습을 시켰을 때, 비교적 고가의 차량이 변수 중요도가 높게 책정됨, 이는 절대적인 가격이 높기 때문에 나타나는 현상
- 실제 예측 모델에서는 총 0.041의 변수중요도를 가졌으며, 가격에 영향을 미치는 요인임을 모델도 학습중에 인식함을 알 수 있음
- 그러나 수익을 얻기 위해서는 저가의 일반 차량을 많이 매매하는 것보다 고가의 고급차량을 한대라도 더 매매하는 것이 바람직하다고 생각함

07 참고문헌

1. IndianBlueBook (2021 Market Insight),
2. Indian pre-owned car market study by OLX Autos in partnership with CRISIL: reveals that pre-owned car market continues to outstrip new car market sales
3. Gears of growth REPORT BY CARS24
4. FADA(Federation of Automobile Dealers Associations of India) Journals
5. XU XIAOYING. "중고차 가격 예측을 위한 머신러닝의 활용." 국내석사학위논문 전남대학교, 2024. 광주

07 프로젝트 소감



김민규

팀끼리 처음 힘을 모으면서 다양한 시점에서 문제를 해석하는것이 즐거웠다.
모르는상황을 공유하고 피드백을 받아 성장하는모습또한 좋았다



오수빈

인도의 중고차 시장 가격을 예측하는 첫 빅데이터 프로젝트를 통해 데이터 하나하나를 분석하는 과정이 무척 흥미로웠다. 다양한 변수들이 가격에 어떤 영향을 주는지 파악하면서 분석의 재미를 느끼고 실제로 모델을 통해 예측해보는 과정도 즐거웠다. 다음 프로젝트에는 조금 더 체계적인 데이터 분석을 할 수 있을 것 같다!



조한흠

음... 제일 먼저 와서 제일 늦게 가는 우리 들... 변수 한개로 3시간 동안 토론하는...
우리는 열등생이 아니라 모범생이다!!

07 프로젝트 소감



양현준

동일 전공이 아닌 다양한 분야의 전공자들과 진행한 첫 프로젝트로서 배울 수 있는 점이 많았다. 무엇보다 조원들과의 지속적인 브레인스토밍을 통해 새로운 관점에서 문제를 볼 수 있었으며, 협업의 중요성을 배울 수 있었다. 입과 전 스스로 느꼈던 부족한 데이터 분석 역량을 실제 계측 데이터를 바탕으로 분석을 진행할 수 있다는 점에서 스스로 성장함을 느낄 수 있었다. 해당 프로젝트를 시작으로 하여 후판 공정 및 빅데이터 프로젝트에 대해 긍정적인 결과를 도출할 수 있을 것이라는 자신감을 얻었다.



김예슬

처음 만나 낯가릴 새도 없어진 우리들, 첫 프로젝트를 무사히 완수함에 감사한다! 처음엔 전공자로서 부담감에 어깨가 무거웠지만, 같이 시간을 보내면서 열심히 공부하고 함께 이겨내려는 의지가 강한 친구들과 함께여서 다행이고 즐거운 경험이었다. 프로젝트를 진행하면서 다양한 전공의 이야기를 듣고, 나는 전혀 생각해보지도 못한 아이디어와 방향성을 발견할 수 있었다. 3주라는 짧고도 긴 시간동안 한층 더 성장함을 느끼며, 앞으로 남은 여러 프로젝트도 팀원들과 어떻게 완성시켜나갈지 또우리가 얼마나 성장할지 기대가 된다! 다음 프로젝트의 발전도 기대해본다.



천정화

이론으로 배웠던 내용을 직접 실습하면서 많은 시행착오를 겪었다. 늦게까지 학습하며 힘든 적도 있었지만, 조원들과 함께 서로 의지하며 이겨낼 수 있었다. y 변수에 영향을 끼치는 많은 x 변수 사이의 상관관계를 파악하는 것이 매우 어려웠지만, 이번 종합설계를 토대로 다음 종합설계에 더 나아진 모습이 되리라 믿는다.

감사합니다