

후판공정 SCALE 불량

B1 조한흠

B1 김민규 김예슬 양현준 오수빈 조한흠 천정화

With POSCO

분석계획

01 문제 정의

- ① 과제 정의
- ② 설명변수 및 목표변수 파악
- ③ 데이터 통계량 파악

02 데이터 특성

- ① 연속형 변수
- ② 범주형 변수

03 데이터 분석

- ① 1차 전처리
- ② 결측치 및 이상치 처리
- ③ 파생변수 생성
- ④ 2차 전처리(변수 통합, 범주화)

04 모델링

- ① 모델 학습 계획 정의
- ② 모델 설명

05 분석 및 결과

- ① 모델 학습 결과
- ② 변수 중요도 분석

06 소감문

- ① 소감문

01 문제 정의




선박 제조에 주로 사용되는
후판 제품의 **"Scale 불량 급증"**



원인 분석 결과, **압연공정**에서의
Scale 불량률이 급증함

발생원인	압입흔	Scratch	두께부족	Scale	계
발생률(%)	1.3	0.5	0.4	5.0	7.2%

발생률(%)



불량의 근본 원인을 찾고, 불량 예측 및 개선 기회 도출

01 문제 정의 - 설명변수 및 목표변수 파악

변수	변수 설명
plate_no	Plate번호
rolling_date	열연작업시각
scale	Scale(산화철) 불량
spec_long	제품 규격
spec_country	제품 규격 기준국
steel_kind	강종
pt_thick	Plate(후판) 지시두께(mm)
pt_width	Plate(후판) 지시폭(mm)
pt_length	Plate(후판) 지시길이(mm)
hsb	HSB(Hot Scale Braker)적용여부
fur_no	가열로 호기
fur_input_row	가열로 장입열
fur_heat_temp	가열로 가열대 소재온도(°C)
fur_heat_time	가열로 가열대 재로시간(분)
fur_soak_temp	가열로 균열대 소재온도(°C)
fur_soak_time	가열로 균열대 재로시간(분)
fur_total_time	가열로 총 재로시간(분)
fur_ex_temp	가열로 추출온도(°C,계산치)
rolling_method	압연방법
rolling_temp	압연온도(°C)
descaling_count	압연Descaling 횟수
work_group	작업조

#	Column	Non-Null Count	Dtype
0	plate_no	1000 non-null	object
1	rolling_date	1000 non-null	object
2	scale	1000 non-null	object
3	spec_long	1000 non-null	object
4	spec_country	1000 non-null	object
5	steel_kind	1000 non-null	object
6	pt_thick	1000 non-null	int64
7	pt_width	1000 non-null	int64
8	pt_length	1000 non-null	int64
9	hsb	1000 non-null	object
10	fur_no	1000 non-null	object
11	fur_input_row	1000 non-null	object
12	fur_heat_temp	1000 non-null	int64
13	fur_heat_time	1000 non-null	int64
14	fur_soak_temp	1000 non-null	int64
15	fur_soak_time	1000 non-null	int64
16	fur_total_time	1000 non-null	int64
17	rolling_method	1000 non-null	object
18	rolling_temp	1000 non-null	int64
19	descaling_count	1000 non-null	int64
20	work_group	1000 non-null	object

01 문제 정의 - 데이터 통계량 파악

```
df_raw.describe()
```

	pt_thick	pt_width	pt_length	fur_heat_temp	fur_heat_time	fur_soak_temp	fur_soak_time	fur_total_time	rolling_temp	descaling_count
count	1000.00000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	26.78200	2831.900000	36788.200000	1157.245000	85.972000	1150.928000	71.720000	238.589000	934.637000	8.557000
std	18.13757	494.081478	13912.387116	21.245007	26.346297	17.344384	20.602137	38.194828	96.598015	1.604158
min	12.00000	1800.000000	7900.000000	1103.000000	55.000000	1113.000000	35.000000	165.000000	0.000000	5.000000
25%	15.00000	2500.000000	26650.000000	1140.000000	66.000000	1135.750000	57.750000	210.000000	893.750000	8.000000
50%	19.00000	2800.000000	40400.000000	1159.000000	75.000000	1156.000000	66.000000	230.000000	948.000000	9.000000
75%	34.00000	3100.000000	49100.000000	1173.000000	102.250000	1164.000000	81.000000	263.000000	991.000000	10.000000
max	100.00000	4600.000000	54900.000000	1206.000000	158.000000	1185.000000	145.000000	362.000000	1078.000000	10.000000


```
df_raw.describe(include='object')
```

	plate_no	rolling_date	scale	spec_long	spec_country	steel_kind	hsb	fur_no	fur_input_row	rolling_method	work_group
count	1000	1000	1000	1000	1000	1000	1000	1000	1000	1000	1000
unique	1000	1000	2	66	7	2	2	3	2	2	4
top	PLT_1001	03JAN2023:07:07:53	양품	JS-SM490YB	영국	C	적용	3호기	1열	CR(제어압연)	2조
freq	1	1	690	84	256	755	953	342	508	840	292

이상치 발견


02 데이터 특성

연속형 변수



02 데이터 특성

범주형 변수



03 데이터 분석 - 1차 전처리



plate_no	rolling_date	scale	spec_long	spec_country	steel_kind	pt_thick	pt_width	pt_length	hsb	fur_no	fur_input_row	fur_heat_temp	fur_heat_time	fur_soak_temp	fur_soak_time	fur_total_time	rolling_method	rolling_temp	descaling_count	work_group
PLT_1001	03JAN2023:07:07:53	양품	AB/EH32-TM	미국	T	32	3700	15100	적용	1호기	1열	1144	116	1133	59	259	TMCP(온도제어)	934	8	1조
PLT_1002	03JAN2023:07:21:22	양품	AB/EH32-TM	미국	T	32	3700	15100	적용	1호기	2열	1144	122	1135	53	238	TMCP(온도제어)	937	8	1조
PLT_1003	03JAN2023:07:31:15	양품	NV-E36-TM	영국	T	33	3600	19200	적용	2호기	1열	1129	116	1121	55	258	TMCP(온도제어)	889	8	1조

1) 목표변수 매핑

```
df_raw['scale'].value_counts()
```

```
양품    690
불량    310
Name: scale, dtype: int64
```

```
scale_o = df_raw.copy()
scale_o['scale'] = scale_o['scale'].map({'불량': 1, '양품': 0})
scale_o['scale'].value_counts()
```

```
0    690
1    310
Name: scale, dtype: int64
```

2) 필요없는 열 제거

- plate_no & rolling_date

```
drop_data = descaling_count_o.copy()
delete_col_list = ['plate_no', 'rolling_date']
drop_data.drop(columns=delete_col_list, inplace=True)
drop_data.info()
```

- 고유값이 1,000개로 모델에 불필요한 영향을 줄 수 있으므로 해당 열은 제거함
- work_group만 사용하므로 rolling_date 제거함

3) 변수 관계 분석

- work_group

rolling_date	work_group
03JAN2023:07:07:53	1조
03JAN2023:07:21:22	1조
:	:
03JAN2023:18:48:00	1조
03JAN2023:19:02:24	2조

▲ 교대시간인 19시를 기준으로 바뀜

- 열연작업시각과 작업조 데이터를 보면
4조 2교대로 시간별로 묶이는 것을 알 수 있음
- 따라서 work_group 데이터만 사용하기로 함

03 데이터 분석 - 1차 전처리

plate_no	rolling_date	scale	spec_long	spec_country	steel_kind	pt_thick	pt_width	pt_length	hsb	fur_no	fur_input_row	fur_heat_temp	fur_heat_time	fur_soak_temp	fur_soak_time	fur_total_time	rolling_method	rolling_temp	descaling_count	work_group
PLT_1001	03JAN2023:07:07:53	양품	AB/EH32-TM	미국	T	32	3700	15100	적용	1호기	1열	1144	116	1133	59	259	TMCP(온도제어)	934	8	1조
PLT_1002	03JAN2023:07:21:22	양품	AB/EH32-TM	미국	T	32	3700	15100	적용	1호기	2열	1144	122	1135	53	238	TMCP(온도제어)	937	8	1조
PLT_1003	03JAN2023:07:31:15	양품	NV-E36-TM	영국	T	33	3600	19200	적용	2호기	1열	1129	116	1121	55	258	TMCP(온도제어)	889	8	1조

4) 변수 추가

- fur_ex_temp

fur_ex_temp

$$T(t) = T_{\infty} + (T_0 - T_{\infty}) \cdot \frac{4}{\pi} \cdot \exp\left(-\frac{\pi^2 \alpha t}{4L^2}\right)$$

▲ 최종 심부 온도 추정을 위한 Heisler 공식 적용

fur_heat_temp, fur_heat_time, pt_thick,
열확산계수(α) 등을 이용해 산출하며
slab가 가열 공정을
마친 시점의 중심부 온도를 근사

5) 원핫인코딩

- steel_kind (T/C)

```
df['steel_kind'].unique()

array(['T', 'C'], dtype=object)
```



steel_kind_C	steel_kind_T
0	1
0	1
0	1
0	1
0	1

- HSB (적용 / 미적용)

```
df['hbsb'].unique()  
  
array(['적용', '미적용'], dtype=object)
```



hsb_미적용	hsb_적용
0	1
0	1
0	1
0	1
0	1

- rolling_method (TMCP / CR)

```
df['rolling_method'].unique()

array(['TMCP(온도제어)', 'CR(제어압연)'], dtype=object)
```



rolling_method_CR(제어압연)	rolling_method_TMCP(온도제어)
0	1
0	1
0	1
0	1
0	1

03 데이터 분석 - 결측치 및 이상치 처리

1) 결측치

결측치 확인


```
df.isnull().sum()
```

```
plate_no      0
rolling_date  0
scale         0
spec_long     0
spec_country  0
steel_kind    0
pt_thick      0
pt_width      0
pt_length     0
hsb           0
fur_no        0
fur_input_row 0
fur_heat_temp 0
fur_heat_time 0
fur_soak_temp 0
fur_soak_time 0
fur_total_time 0
rolling_method 0
rolling_temp  0
descaling_count 0
work_group    0
fur_ex_temp   0
dtype: int64
```


결측치 없음

2) 이상치

두께, 폭은 불량여부에
유의미한 영향을 미칠 수도
있으므로 제거 하지 않음




실제 압연온도는
800~1000°C 이므로 이 값은
중앙값으로 대체함



균열대, 총 시간은 불량여부에
유의미한 영향을 미칠 수도
있으므로 제거하지 않음

03 데이터 분석 - 파생 변수 생성(Spec_long&Spec_country)

Class_code



Spec_country는 단순히 국가만 나타냄(KR, US, JP 등)
반면, 파생변수 class_code는 한 단계 더 세분류 함

Ex) 미국 :

- ABS → 선급기관 (American Bureau of Shipping)
- ASTM → 시험 재료 협회
- API → 석유 산업 전용 강제 규격

같은 국가라도 품질 기준, 용도, 공정 기준이 다름
즉, 더 작은 단위로 구분할수록 불량 예측력이 올라갈 것이라 가정

03 데이터 분석 - 파생 변수 생성

Class_code

```
'카이제곱 p-value': 1.7792953767748386e-21,
```

	class_code	scale_rate	sample_count
4	CCS	1.000000	2
8	JS	0.603896	154
10	KS	0.566667	30
2	ASTM	0.562500	32
11	LR	0.317881	151
9	KR	0.313725	102
6	DNV	0.257143	105
0	ABS	0.208000	125
3	BV	0.191489	141
7	GL	0.149425	87
12	NK	0.121212	33
5	Common	0.083333	36
1	API	0.000000	2

귀무가설	Class_code에 따라 scale 분포에 차이가 없다
대립가설	Class_code에 따라 불량률의 분포에 차이가 있다


p-value = $1.78 * 10^{-21}$

귀무가설 기각

"Class_code에 따라 불량률의 분포에 차이가 있다"

03 데이터 분석 - 이상치 처리

rolling_temp



실제 압연온도는
800~1000°C 이므로 이상치를
중앙값으로 대체함

```
rolling_temp_o[rolling_temp_o['rolling_temp'] == 0]
```

t_time	fur_soak_temp	fur_soak_time	fur_total_time	rolling_method	rolling_temp	descaling_count	work_group	class_code
95	1128	80	244	TMCP(온도제어)	0	6	1조	GL
57	1166	67	228	CR(제어압연)	0	10	2조	JS
64	1164	61	188	CR(제어압연)	0	10	2조	JS
89	1122	59	229	CR(제어압연)	0	6	3조	KR
92	1124	61	210	CR(제어압연)	0	6	3조	KR
109	1117	76	260	TMCP(온도제어)	0	6	3조	DNV

총 6개의 이상치 발견 ⇒ 중앙값으로 대체

```
# 중앙값으로 대체
find_median = rolling_temp_o[rolling_temp_o['rolling_temp'] != 0]['rolling_temp'].median()
rolling_temp_o['rolling_temp'] = rolling_temp_o['rolling_temp'].replace(0, find_median)
rolling_temp_o['rolling_temp'].describe()
```


```
count    1000.000000
mean      940.325000
std        63.665836
min       723.000000
25%      894.000000
50%      948.000000
75%      991.000000
max     1078.000000
Name: rolling_temp, dtype: float64
```

```
rolling_temp_o[rolling_temp_o['rolling_temp'] == 0]['rolling_temp']
```


```
Series([], Name: rolling_temp, dtype: int64)
```

⇒ 이상치 없음 확인

03 데이터 분석 – Heatmap & Pairplot





서로 상관관계를 가지는 변수들이 존재함




서로 선형관계를 가지는 변수들이 존재함

03 데이터 분석 - 중복 변수 통합

fur_ex_temp & fur_heat_temp & fur_soak_temp




	fur_soak_temp	fur_ex_temp
0	1133	1133.0
1	1135	1135.0
2	1121	1121.0
3	1127	1127.0
4	1128	1128.0



- 가열로 균열대에서 후판 내부까지 열평형이 이루어지므로, 추출온도 또한 동일한 온도를 가짐
- 상관계수를 확인했을 때, 1.00이 나오므로 계산치인 **fur_ex_temp**를 제거


03 데이터 분석 - 중복 변수 통합

fur_heat_time & fur_soak_time & fur_total_time



03 데이터 분석 - 중복 변수 통합



pt_thick & pt_width & pt_length



- 전체 heatmap을 확인했을 때, `pt_length`와 `pt_thick`의 상관계수가 -0.87로 높은 음의 상관관계를 가지고 있음을 확인
- 이에 따라 `pt_length`, `pt_width`, `pt_thick`의 관계성을 확인하기 위하여 **`pt_area`(면적)**을 구하고 분포를 확인
- 구한 `pt_area`(면적)과 `pt_thick`의 분포를 확인하였더니 반비례 관계를 보임
- 따라서 상관계수가 높은 **`pt_length`**를 제거

03 데이터 분석 - 범주화


descaling_count



- descaling_count 값의 빈도를 확인했을 때, 홀수 번 시행과 짝수 번 시행이 극단적인 차이를 보이므로 5~6 / 7~8 / 9~10 으로 묶어서 처리

04 모델링

모델 학습 계획 정의 : 파이프 라인





- 전처리 된 데이터는 학습데이터 60%, 검증데이터 40%로 분리하여 각각 학습하여 검증에 사용함
- 모델 검증을 위한 성능지표로는 Accuracy, Precision, Recall, Specificity, F1-score, AUC를 사용함

04 모델링

모델 학습 계획 정의 : 모델 설명

Random Forest

- 여러 개의 decision tree를 결합한 앙상블(bagging) 모델
- 과대적합 방지 기능
- 높은 정확도와 안정성 제공



Gradient Boosting



- 여러 개의 decision tree를 순차적으로 결합한 모델
- 이전 모델의 오차를 개선하며 점진적으로 성능 향상
- 예측 성능이 매우 우수함

04 모델링

모델 학습 계획 정의 : 모델 설명

SVM(Support Vector Machine)

- 분류와 회귀 문제 모두에 사용되는 지도학습 모델
- 데이터의 경계를 최대한 분리하는 벡터를 찾아 예측함
- 고차원 데이터에서도 강력한 성능을 보임



NN(Neural Networks)

- 인간의 뇌의 신경망을 모방한 모델
- 비선형 관계를 학습하여 복잡한 패턴 인식 성능이 뛰어남
- 대규모 데이터를 다룰 수 있으며, 딥러닝 모델로 확장 가능

04 모델링

모델 학습 계획 정의 : 모델 설명

accuracy(정확도)

- 전제 데이터 중 모델이 올바르게 예측한 비율
- 데이터의 균형이 올바를 때 유용하나, 불균형 데이터셋에서는 성능을 제대로 평가하기 어려움

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

recall(재현율)

- 실제 양성 데이터 중 모델이 양성으로 예측한 비율
- 양성 데이터를 맞추는 게 중요한 모델일 경우 주시해야 하는 성능 지표

$$Recall = \frac{TP}{TP + FN}$$

precision(정밀도)

- 모델이 양성으로 예측한 것 중 실제로 양성데이터인 비율
- 잘못된 양성 예측을 피하고자 할 때 중요한 성능지표

$$Precision = \frac{TP}{TP + FP}$$

04 모델링

모델 학습 계획 정의 : 모델 설명

specificity(특이도)

- 실제 음성 데이터 중 모델이 음성으로 예측한 비율
- 불필요한 양성예측을 줄이는 데 사용

$$Specificity = \frac{TN}{FP + TN}$$

F1-score(조화평균)

- precision과 recall의 조화평균
- 두 성능지표 간의 균형을 고려하며 모델의 전반적 성능을 평가할 때 유용

$$F1 - score = 2 * \frac{Recall * Precision}{Recall + Precision}$$


auc

- roc curve 아래의 면적을 의미, 1에 가까울수록 성능이 우수함
- 모델이 양성과 음성을 구분하는 능력을 평가하며, 불균형 데이터셋에 유용함

$$AUC = \sum_{i=1}^{n-1} \frac{(FPR_i - FPR_{i-1})(TPR_i + TPR_{i-1})}{2}$$

05 분석 및 결과

변수중요도를 사용한 핵심인자도출 및 모델의 최적화 시도



목표변수 예측에
불필요한 변수 도출





핵심인자 도출을 통한
모델의 최적화



후판 제조 공정에서의
불량 원인 파악 및 개선방안 탐색

05 분석 및 결과

모델 학습 결과 – Random Forest



1차 모델

	RF-train	RF-test	RF-diff	GB-train	GB-test	GB-diff
Accuracy	0.868333	0.865000	0.003333	0.963333	0.960000	0.003333
Precision	0.942623	1.000000	-0.057377	1.000000	1.000000	0.000000
Recall	0.614973	0.560976	0.053998	0.882353	0.869919	0.012434
F1_score	0.744337	0.718750	0.025587	0.937500	0.930435	0.007065
Specificity	0.983051	1.000000	-0.016949	1.000000	1.000000	0.000000

- train과 test 모두 **FN(72,54)**이 낮아 Recall이 낮게 나옴
- 정확도는 train과 test 모두 **87%** 정도로 양호한 수준임을 확인할 수 있음

⇒ 특정 설명변수에 의해서 예측 결과가 결정될 수 있기에 **데이터 처리 필요**



2차 모델

	RF-train	RF-test	RF-diff	GB-train	GB-test	GB-diff
Accuracy	0.881667	0.867500	0.014167	0.923333	0.910000	0.013333
Precision	1.000000	1.000000	0.000000	1.000000	0.988764	0.011236
Recall	0.620321	0.569106	0.051215	0.754011	0.715447	0.038564
F1_score	0.765677	0.725389	0.040288	0.859756	0.830189	0.029567
Specificity	1.000000	1.000000	0.000000	1.000000	0.996390	0.003610

- 기존 모델 대비 Recall이 향상되긴 했지만 여전히 낮은 수치를 보여줌
- 정확도는 기존 모델 대비 **88% 정도 향상된** 것을 확인할 수 있음

05 분석 및 결과

모델 학습 결과 – Gradient Boosting



1차 모델

	RF-train	RF-test	RF-diff	GB-train	GB-test	GB-diff
Accuracy	0.868333	0.865000	0.003333	0.963333	0.960000	0.003333
Precision	0.942623	1.000000	-0.057377	1.000000	1.000000	0.000000
Recall	0.614973	0.560976	0.053998	0.882353	0.869919	0.012434
F1_score	0.744337	0.718750	0.025587	0.937500	0.930435	0.007065
Specificity	0.983051	1.000000	-0.016949	1.000000	1.000000	0.000000



2차 모델

	RF-train	RF-test	RF-diff	GB-train	GB-test	GB-diff
Accuracy	0.881667	0.867500	0.014167	0.923333	0.910000	0.013333
Precision	1.000000	1.000000	0.000000	1.000000	0.988764	0.011236
Recall	0.620321	0.569106	0.051215	0.754011	0.715447	0.038564
F1_score	0.765677	0.725389	0.040288	0.859756	0.830189	0.029567
Specificity	1.000000	1.000000	0.000000	1.000000	0.996390	0.003610

- RF와 마찬가지로 **FN(70, 52)**이 낮아 Recall 이 낮게 나옴 오히려 RF보다 낮은 수치
 - 정확도는 train과 test 모두 **88%** 정도로 양호한 수준임을 확인할 수 있음
- ⇒ 마찬가지로 특정 설명 변수에 의해 예측 결과가 결정될 수 있기에 데이터 처리 필요
- TN에 대해 train test 모두 높은 예측을 보여줌
 - 여전히 **FN**에 대한 문제가 존재하고 **Recall**이 낮은 문제가 있음
- ⇒ 데이터 처리를 진행하여 일반화 가능한 모델을 제작했지만, 추가적인 조치를 통해 모델 개선 필요

05 분석 및 결과

모델 학습 결과 - NN



1차 모델

	NN-train	NN-test	diff
Accuracy	0.996667	0.897500	0.099167
Precision	1.000000	0.879630	0.120370
Recall	0.989305	0.772358	0.216947
F1_score	0.994624	0.822511	0.172113
Specificity	1.000000	0.953069	0.046931

2차 모델

	NN-train	NN-test	diff
Accuracy	0.976667	0.805000	0.171667
Precision	0.994286	0.710280	0.284005
Recall	0.930481	0.617886	0.312595
F1_score	0.961326	0.660870	0.300456
Specificity	0.997579	0.888087	0.109492

Train Accuracy : 0.997

Test Accuracy : 0.897

⇒ Train의 과적합 가능성 높음

⇒ 불량에 대한 재현율이 0.772로 불량 검출률 개선 필요

Train Accuracy: 0.977

Test Accuracy: 0.805



⇒ 과적합이 심화됨

⇒ Test 정확도가 떨어지고, 재현율이 0.618로 떨어짐

⇒ 하이퍼파라미터 튜닝이나 변수선택의 재조정 필요

05 분석 및 결과

모델 학습 결과 - SVM



1차 모델

	SVM-train	SVM-test	diff
Accuracy	0.968333	0.905000	0.063333
Precision	0.988372	0.904762	0.083610
Recall	0.909091	0.772358	0.136733
F1_score	0.947075	0.833333	0.113742
Specificity	0.995157	0.963899	0.031258

Train Accuracy : 0.992

Test Accuracy : 0.828

⇒ Train의 과적합 가능성 높음

⇒ 불량에 대한 재현율이 0.675로 불량 검출률 개선 필요

2차 모델

	SVM-train	SVM-test	diff
Accuracy	0.921667	0.847500	0.074167
Precision	0.948718	0.810000	0.138718
Recall	0.791444	0.658537	0.132907
F1_score	0.862974	0.726457	0.136516
Specificity	0.980630	0.931408	0.049222

Train Accuracy : 0.937

Test Accuracy : 0.807



⇒ 과적합이 심화됨

⇒ 하이퍼파라미터 튜닝이나 변수선택의 재조정 필요

05 분석 및 결과

변수중요도 분석

성능이 좋은 GB를 기준으로 불필요한 변수 제거



- fur_input_row, fur_no 는 두 모델에서의 영향력이 낮아 제거
- descaling_count는 연속형이지만 scale과의 연관성이 보이지 않아 제거
- hsb는 변수중요도가 높았으나, hsb가 미적용인 경우 모든 scale이 불량인데다가 적용의 경우는 양품/불량이 섞여 있기 때문에 오히려 모델 학습에 방해가 된다고 판단하여 제거

06 소감문



김예슬

처음 보는 단어들과, 개념이 어려웠고 모델을 설계할 때 도메인 지식을 충분히 아는 것 또한 중요함을 깨닫게 되는 프로젝트였습니다. 더불어 협업프로젝트를 함께 하는데 있어 혼자 하는 것보다 더 많은 것들을 생각하고 조율하며 계획을 세워야 하는 것을 알 수 있었습니다. 시작은 미약했으나 끝은 창대하리라

양현준

어제보다 오늘 더 성장한 나를 볼 수 있었다! 비전공 계열에 대한 주제이기에 스스로 이해하는 데 어려움이 있었지만, 전공자인 조원의 도움으로 후판 공정에 대한 지식 또한 향상할 수 있었던 유의미한 경험이었다. 본 빅데이터 프로젝트 대기해

오수빈

이번 후판공정 프로젝트를 진행하면서, 전공인 철강에 대한 지식을 바탕으로 데이터분석을 진행했습니다. 특히, 데이터 각 변수 하나하나를 면밀히 검토하고 해석해 나가는 과정이 매우 흥미로운 과정이었습니다. 또한 이러한 경험을 통해 실제 철강 산업 현장에서의 문제해결에 초점을 맞춘 데이터 분석 역량을 키울 수 있었습니다.

저는 이번 프로젝트를 통해 얻은 경험을 바탕으로, 앞으로 진행할 본 프로젝트에서도 체계적으로 접근해 나가며 실제 산업 현장에서 활용 가능한 인사이트 도출에 중점을 두어 프로젝트를 이끌어갈 계획입니다

조한흠

Spec_long에서 선급사 코드를 뜯어냈을 때 너무 기뻐했는데, 중간에 남은 코드들을 원소함량이나 항복점으로 바꾸지 못해서 아쉬웠다. 다음 프로젝트 두고 봐

천정화

이전 프로젝트를 기반으로 이번 프로젝트에서는 조금 더 원활하게 할 수 있었다. 변수가 많고 상관관계와 도메인 지식과 관련하여 어려움이 많았지만, 성공적으로 프로젝트를 마무리하여 성취감이 생겼다. 앞으로의 프로젝트에서도 더 잘할 수 있을 것이라는 자신감이 생겼다

감사합니다.